CIE 全国 RISC-V 高水平创新及应用大赛（第二届） · 进迭时空赛道

K1 上的 Qwen3.5-2B/4B 本地部署与性能优化

模型： Qwen3.5-2B / Qwen3.5-4B （官方权重，本地量化） · 平台： SpacemiT K1 ， 8 GB

2B 预填 25.3 t/s | 4B 预填 9.84 t/s | 首 token 降低 30%—43% | 生成领先 MEE 约四成

赛题二 · 基于 K1 AI CPU 的大模型部署落地 | 2026-11-08

OVERVIEW

研究概览

问题

- K1 无 vmadot，矩阵引擎仅覆盖 4 核
- 8.17 GB/s 带宽限制生成吞吐
- 直接部署：预填 5 t/s、生成 2.8 t/s
- 32K 单档预填需 65—119 分钟

方法

- 自量化 Q4_0，词嵌入保留 Q6_K
- 7 个内核补丁，1876 行
- 线程解耦、四路并发、KV 复用
- 四层改造均给出同板对照

结果

- 预填 25.3 / 9.84 t/s
- 首 token 降低 28.9%—42.6%
- 生成领先 MEE 41.9% / 45.8%
- 8K 深度生成保留 85.1%

全部推理在板端完成　　97 条 claim 与 307 条归档实验可供复验

PLATFORM

平台约束与直接部署的基线

无 vmadot 点积指令

RVV 的 GEMV 需拆分为乘加序列，计算密度低

矩阵引擎仅覆盖 4 核

ime 只在 cpu0—cpu3 可用，仅支持 i8i4 / i8i8 格式

内存带宽 8.17 GB/s

生成每 token 读取全部权重： 2B 1.20 GB 、 4B 2.54 GB

stock 构建的直接部署结果

指标	2B	4B
预填 t/s	5.05	1.95
生成 t/s	2.80	1.25
首 token （128）	7.10 s	18.48 s

预填受算力约束，生成受带宽约束。

PROTOCOL

测量协议与口径

同板 ABBA

同一块板按 A/B/B/A 顺序测量，抵消热漂移；两轮结果取中位。

冷启动与缓存命中

每次冷启动前重启服务， KV 为空；缓存命中为同一提示的第二次请求。

多板统计

多块板各取中位，再取板间中位与极差；首 token 报告 4 板极差。

指标定义

预填 pp512 的 t/s 、生成 tg128 的 t/s 、首 token 端到端计时。

所有结果文件登记 SHA256 ， 材料中的数字均可回溯到证据 JSON 。

METHOD

四层改造

模型层

自量化 Q4_0，共享词嵌入保留 Q6_K

PPL +4.4%

内核层

repack、CONCAT、GQA、chunk16 共 7 个补丁

预填 3.86×（同模型）

调度层

预填 8 线程、生成 7 线程，四路并发

并发 +24.0%

长上下文

KV 落盘复用与 checkpoint 增量重算

0.70 s / 26.6 s

全部改造基于官方 spacemit-com/llama.cpp，不引入新的推理框架。

交付构建 lib16 = 4436a9f4； 2B 1,202,487,136 B， 4B 2,543,899,168 B。

QUANTIZATION

量化配方与质量代价

- 官方 Q4_1 为混合格式： 186 个 Q4_1 、 1 个 Q6_K 词嵌入、 133 个 F32 。
- 交付配方采用 Q4_0 ， 使线性层全部落入 repack 快路径。
- token_embd 保留 Q6_K ， 避免输出头精度损失。
- 量化命令固定 output-tensor-type 与 token-embedding-type 为 Q6_K 。

困惑度相对第三方混合配方

语料	2B	4B
小语料	+4.44%	+3.53%
扩语料	+4.06%	+5.56%
跨域	−1.36%	+7.89%

```
llama-quantize --output-tensor-type Q6_K --token-embedding-type Q6_K  f16.gguf  Q4_0 8
```

KERNEL

内核改造： 7 个补丁、 1876 行

补丁	内容	增量	效果
01	Q4_1 16×1 repack	+374 行	官方格式 3.70× / 3.65×
02	CONCAT 快速路径	+29 行	预填 +17%
03	GQA 折叠	+154 行	深度 0 +1.2%， 不计入主归因
04	Q5_K repack	+549 行	Q4_K_M 预填 +95.4%
05	Q6_K repack	+300 行	回馈上游
06	Q3_K repack	+455 行	回馈上游
07	chunk16 分块	+15 行	预填 +20.8% / +36.7%

01—03 已合入源码包； 04—07 为独立补丁。三套 K-quant 补丁在上游 master 0.7.0 上内核逻辑零改动， Q4_K_M 预填 +98.5% 。

SCHEDULING & KV

调度与长上下文管理

线程与并发

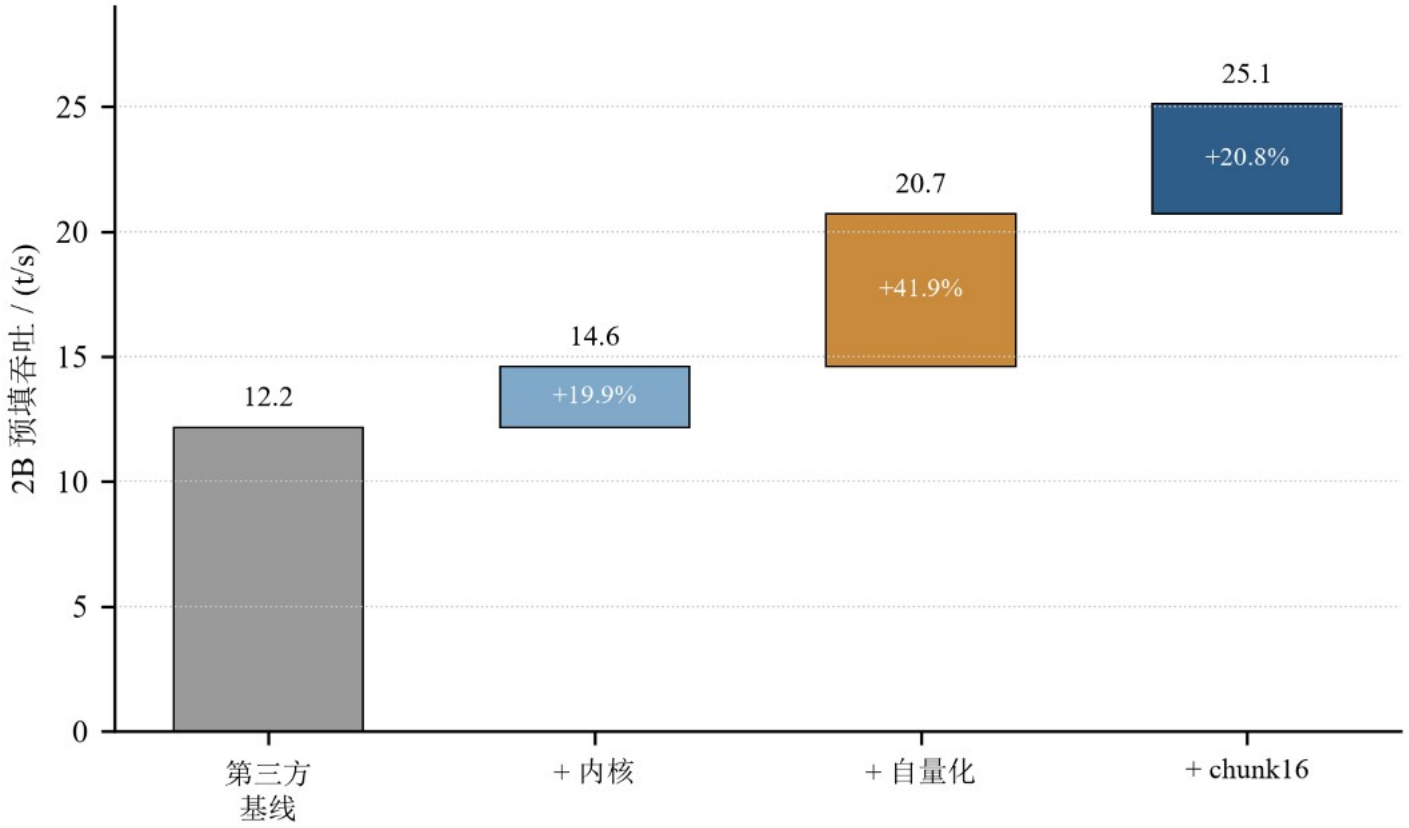
- 预填使用 8 个线程，生成退至 7 个线程（-t 7 --threads-batch 8）。
- 生成阶段线程过多会加剧缓存争用， 7 线程为实测最优点。
- 8 GB 板四路并发： 2B 聚合 +24.0% （4.307 vs 3.472 t/s）。
- 4B 短输出臂 +31.5%，长输出臂 +14.6%，预填争用 8 核。

KV 与长上下文

- 6077 token 提示 KV 落盘 135.6 MB，恢复耗时 240.7 ms。
- 同一提示再次请求：预填 276.2 s 降至 0.698 s。
- 同一文档换问题：从 checkpoint 重算约 512 token，26.6—27.3 s。
- 该路径输出与冷启动逐字节一致，属无损复用。

RESULT • PREFILL

预填性能



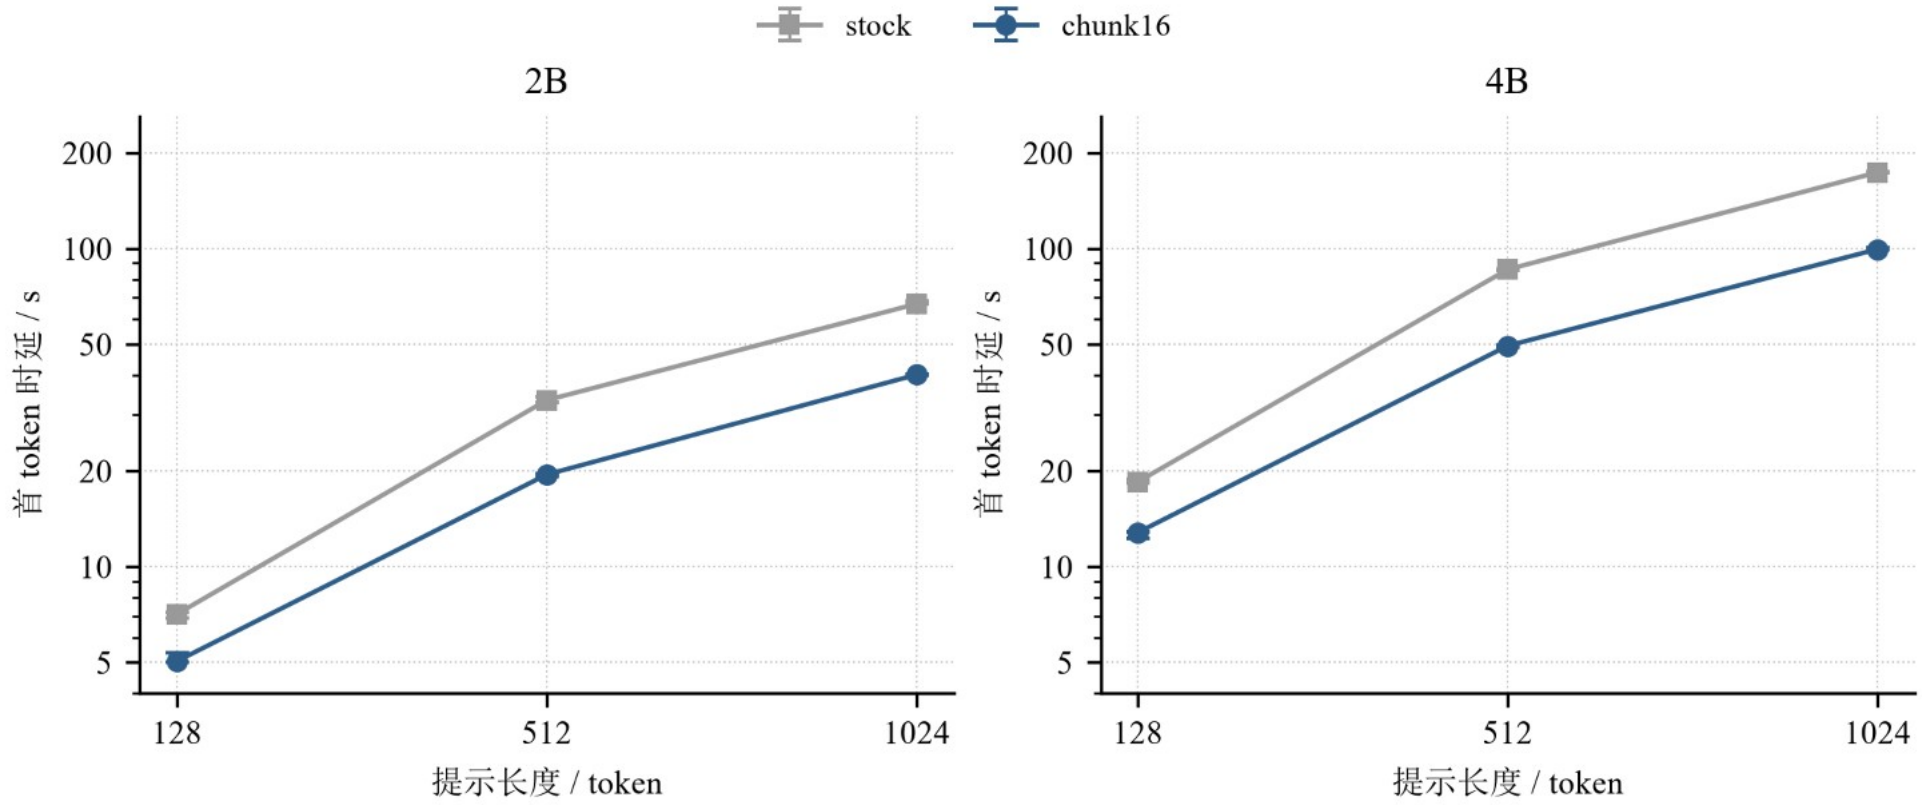
指标	2B	4B
交付构建	25.29	9.84
官方格式基线	5.02	1.96
提升（部署）	5.04×	5.02×

- 2B 8 板中位， IQR 25.12—25.55 。
- 4B 3 板： 9.838 / 10.007 / 9.756 。

图 1　2B 预填的四段分解： 12.2 → 14.6 → 20.7 → 25.1 t/s

RESULT • TTFT

首 token 时延



2B： 5.05 / 19.49 / 40.15 s　　4B： 12.81 / 49.47 / 99.56 s　　相对 stock 降低 28.9%—42.6%（128 / 512 / 1024 token， 4 板中位)

RESULT • DECODE

生成性能与深度保留

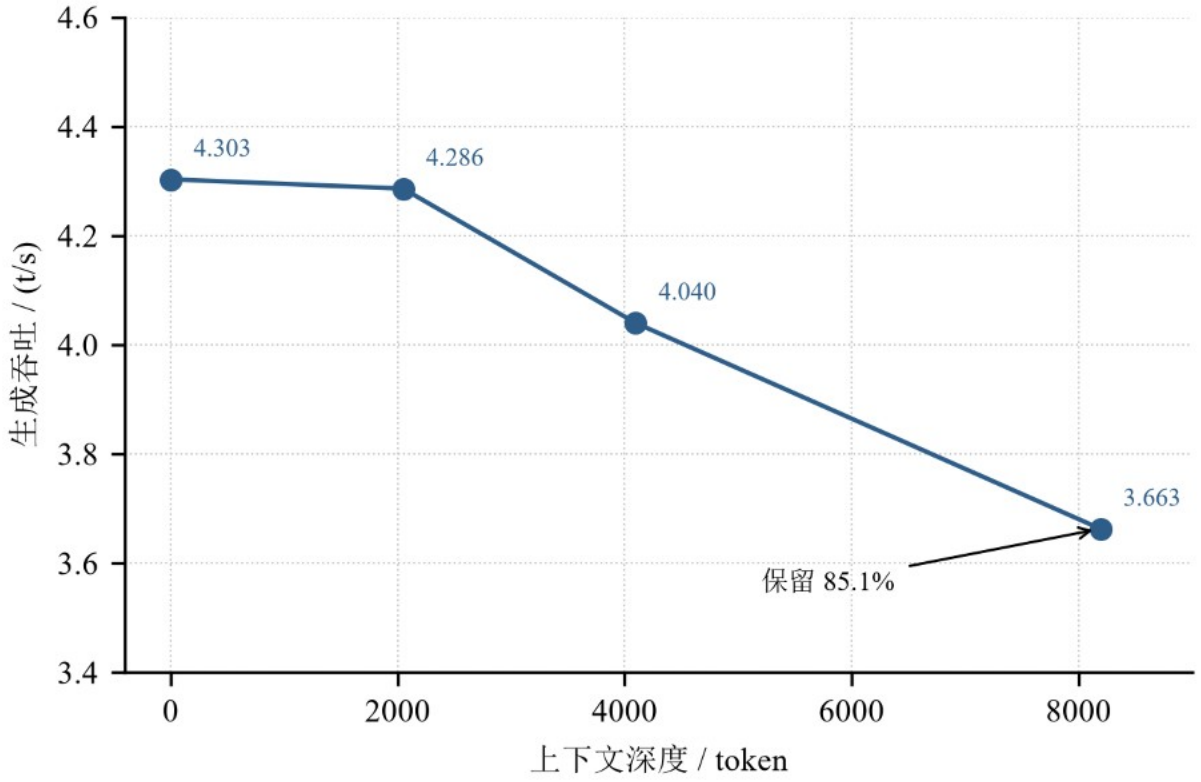


图 2　2B 生成吞吐随上下文深度的变化

- 2B 生成 3.91 t/s （t8@512， 8 板中位）。
- 2B 生成 4.37 t/s （t7 零深度， 114 单板）。
- 4B 生成 2.01 t/s （t7 零深度）， 4 板中位 1.97。
- 8K 深度保留 85.1%，生成随深度衰减平缓。
- 4B 相对 stock 仅 +3.0%，受 8.17 GB/s 带宽限制。

RESULT • CONTEXT

长上下文： 1K—32K 曲线

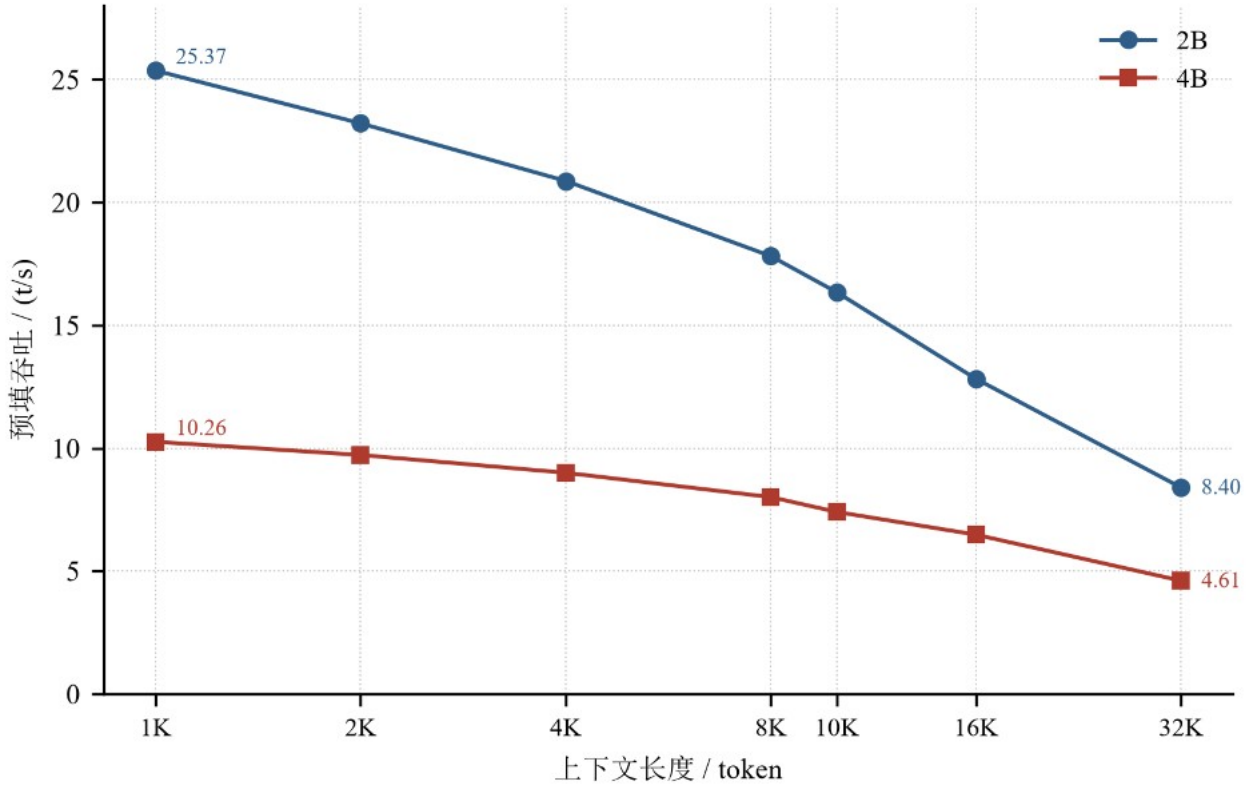
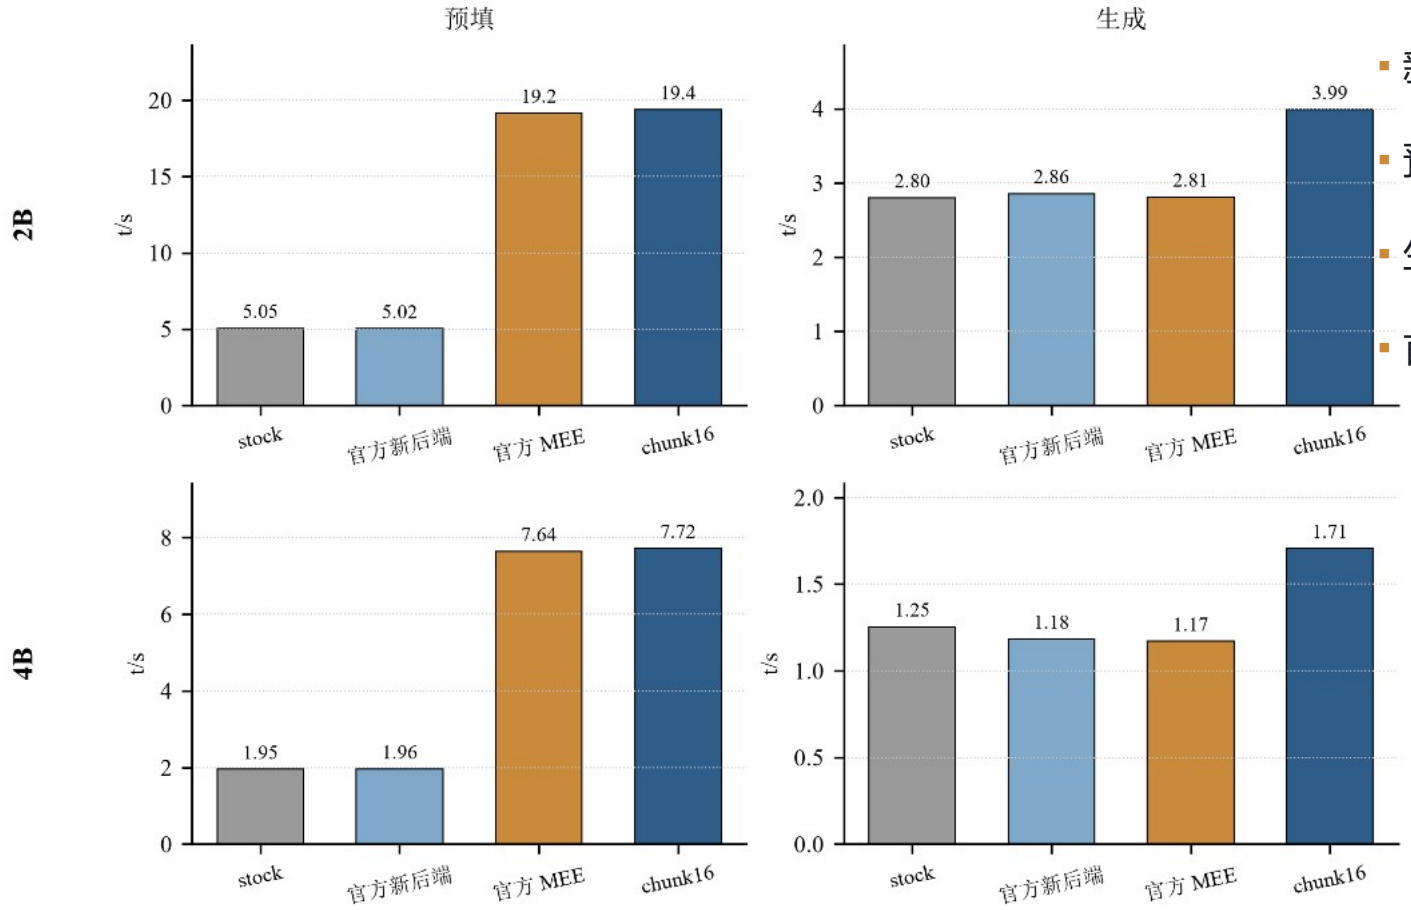


图 4　预填吞吐随上下文长度的变化（对数横轴）

- 2B 25.37→8.40 t/s （– 59.4% ）； 4B 10.26→4.61 t/s （– 50.4% ）； 单调、无悬崖。

ATTRIBUTION

同板四臂归因



- 新后端不加速（− 0.5% / +0.4%）
- 预填与 MEE 同档（+1.15% / +1.02%）
- 生成领先 MEE （+41.9% / +45.8%）
- 首 token 降 28.9%—42.6% （stock A/B）

图 5 同板四臂：预填与生成（官方 Q4_1， t8， ABBA 两轮）

QUALITY

质量评估

困惑度（相对第三方混合配方）

语料	2B	4B
小语料	+4.44%	+3.53%
扩语料	+4.06%	+5.56%
跨域	−1.36%	+7.89%

固定测试集（20 题，命中 ≥ 0.8 记通过）

模型	平均覆盖	通过率
2B 交付模型	0.75	45%
4B 交付模型	0.875	70%
第三方 4B	0.871	13/20

关键词判分口径偏严；4B 与第三方同题集对比略优，2B 覆盖 0.75 。

质量优先配置：Q4_K_M + Q5_K 内核，预填约 13.6 t/s ，PPL 代价显著降低。

LIMITS

边界与负结果

边界	数据	说明
长上下文相对衰减	−59.4% / −50.4% （4K→32K）	斜率由 $O(L^2)$ 主导，未改善
4B 生成相对 stock	+3.0% （t7 零深度）	已接近 8.17 GB/s 带宽上限
4B 32K 预填	7111 s （119 分钟）	仅作压力数据，不作时延承诺
质量代价	PPL +4%—5.6%	速度与质量的取舍
已证伪方向	n-gram 、 MTP 、 FA 、 KV 量化、 TCM 、 THP	共 9 项，均有证据文件

负结果与边界同时列出，避免将局部收益表述为普适结论。

EVIDENCE

证据与复现

97
条 claim
每条绑定证据文件与 SHA256

307
条归档实验
原始 JSON 可逐条校验

1
条命令
包内自包含，无需访问仓库

5
分钟 / 板
tar 包与三个部署脚本

```
cd 08_证据与复验  &&  python tools/verify_claims.py      →  97/97 通过
```

- 提交包内含方案书、技术报告、部署指南、证据与校验脚本，评审无需访问外部仓库。
- 附录 E 为 97 条 claim 的逐条索引，正文 C 编号可直接对照。

VALUE

应用场景与价值

场景	现状	本项目的形态	关键指标
设备报警处置	查阅手册与咨询， 10—30 分钟	报警与参数输入， 20 秒内给出步骤	首 token 5.05 / 12.81 s
班次巡检报告	手工编写 20—40 分钟 / 班	数据与模板输入， 2 分钟生成	512 token 首 token 19.49 s
长文档问答	每次重新检索	首次预填后缓存，后续秒级	0.70 s / 26.6—27.3 s

- 单线年节省约 1.68 万元，终端 1,500 元计，回本约 1.1 个月（假设—计算，可替换）。
- 千元级、离线、工业温区，与云端 API 、边缘 GPU 、 ARM 盒子形成差异。
- 前序 K1 样机连续运行 24 小时采集 10.8 万条样本；本项目将本地模型从 0.6B 提升至 2B/4B 。

结论

在千元级、 8 GB 的 RISC-V 平台上，2B/4B 已达到工业离线值守可用的档位。

- 预填与厂商矩阵引擎同档，生成领先约四成，首 token 降低三到四成。
- 长文档重复提问降至秒级；同文档换问题 26.6—27.3 s ， 输出无损。
- 全部数字可复验，边界与负结果一并公开。

后续工作：多文档缓存管理、 KV 量化、跨平台迁移验证。